

Catégoriser les questions automatiquement



stack
overflow

Sommaire

- Présentation du projet
- Lister les Tags
- Traitement du texte
- Topic modeling
- LDA, modèle non supervisé
- Term frequency inverse document frequency (Tf-idf)
- Test de différents modèles supervisés avec Tf-idf
- Word embeddings
- Modèles supervisés
- Conclusion



Présentation du projet




Comment attribuer les tags à des questions?

- Référencer les tags les plus utilisés
- Lister les mots les plus récurrents dans les questions
- Vectoriser les sacs de mots
- Développer un programme d'attribution des tags





Lister les Tags

- Tri par nombre d'occurrence
- Sélection des 30 tags plus fréquents
- Problème multi labelling





Topic modeling

- Utilisation de la méthode Latent Dirichlet Allocation (LDA)
- Modèle non supervisé.
- Assignation d'un nombre de topics




LDA, modèle non supervisé



Term frequency inverse document frequency (Tf-idf)


- Matrice de la fréquence d'apparition des termes ($tf(t, d)$)
- Matrice de l'inverse de la fréquence des documents ($idf(t, D)$)
- Plus tfidf est bas, moins le terme intéresse



$$tfidf(t, d, D) = tf(t, d) \cdot idf(t, D)$$




Test de différents modèles supervisés avec Tf idf

- Mesure Hamming score
- GridSearch avec OnevsRest




Word embeddings

- Word2Vec
- Bidirectional Encoder Representations from Transformers
- Universal Sentence Encoder



Modèles supervisés

- BERT
- Word2Vec
- USE
- GridSearch avec OnevsRest



Conclusion

USE modèle d'embedding le plus efficace
pour le modèle de Linear SVC

